# Instituto Tecnológico de Ciudad Juárez TecNM

## **Análisis Inteligentes de Datos**

Adquisición de datos mediante un CSV

#### **Alumno**

Torres Santos José Ángel

#### **Docente**

Oscar Alonso Cobos Cruz

Ciudad Juárez, Chih., a 18 octubre de 2023

# Contenido

Introduccion	3
Contexto	4
Python, CSV y MongoDB: Transformando Datos con Eficacia	5
Python Code: La introducción	7
Librerías necesarias	7
Os	7
CSV	7
Pymongo	8
Python Code: Conexión, Clases y funciones	9
Python Code: Primeras líneas de construcción	10
Python Code: Iterando sobre la carpeta contenedora	11
Python Code: índices a los archivos	12
Python Code: Lecturas y vistas de CSVs	13
Python Code: Insertando datos CSVs en colecciones MongoDB	15
Python Code: Código final	17
MongoDB: Sin relaciones es mejor	18
Python & MongoDB: Insertando datos CSVs	19
Terminal VSCode	19
MongoDB: Base de datos y colecciones	23
Python & MongoDB: Procesando diccionarios a colecciones	24
Ejemplo dataset 150k	25
Conclusiones	26

#### Introduccion

En la era digital actual, la gestión eficaz de datos es esencial para cualquier empresa o proyecto. Python, un lenguaje de programación versátil y poderoso, se ha convertido en la herramienta preferida para muchos desarrolladores debido a su sintaxis sencilla y a su capacidad para manejar datos de diversas formas. Uno de los formatos de datos más comunes es el archivo CSV (Comma-Separated Values), utilizado para almacenar datos tabulares de forma sencilla y legible.

Esta práctica explorará cómo Python puede ser utilizado para procesar archivos CSV de manera eficiente. Aprenderemos a leer y escribir datos en formato CSV utilizando las capacidades integradas de Python y cómo estas habilidades pueden ser ampliadas mediante el uso de bibliotecas especializadas. Además, examinaremos cómo los datos extraídos de archivos CSV pueden ser almacenados y gestionados en una base de datos NoSQL como MongoDB.

MongoDB, una base de datos NoSQL altamente escalable y flexible, es particularmente adecuada para el almacenamiento de datos no estructurados o semiestructurados como los provenientes de archivos CSV. A lo largo de este artículo, descubriremos cómo conectar Python a MongoDB y cómo podemos transformar y cargar datos desde archivos CSV a una base de datos MongoDB. Exploraremos también algunas mejores prácticas para la manipulación eficiente de datos en MongoDB utilizando Python.

Este viaje exploratorio nos permitirá entender cómo Python, en combinación con archivos CSV y MongoDB, puede ser utilizado para gestionar y transformar datos de manera eficaz, proporcionando así una base sólida para proyectos de análisis de datos, desarrollo web y muchas otras aplicaciones que requieran un manejo eficiente de información.

Contexto

Se asigno la tarea de analizar un archivo CSV, para la clase de Análisis Inteligente

de Datos 1, el profesor, nos facilitó un dataset, en el cual deberíamos leer y

posteriormente guardarlo en una base de datos. Para efectuar esto en un principio

se optó por Python & MySQL, pero como este último en relacional, es decir, tiene

una estructura, se dificulto la manera de analizar más de un archivo CSV, debido a

que el programa solo se hizo para un CSV con una estructura especifica.

Por ende, se optó por No-SQL, bases de datos no relacionales, para este caso

Python & MongoDB (previamente instalado), con esta combinación si se pudo

analizar cualquier archivo CSV y posteriormente almacenarlo en la base de datos,

resulto tan bien, que se le agregaron características que, le dan más valor al

programa/script. Cabe recalcar que, cuando se almacena el CSV este se guarda

con el nombre propio del CSV.

El proceso es sencillo:

1. Abrir y leer el CSV.

2. Leerlo como un diccionario.

3. Almacenarlo en una lista

4. Transformarlo a un diccionario

Mostrar el contenido de CSV

6. Preguntar si se quiere almacenar el CSV en una base de datos.

7. Insertar datos del CSV con su propio nombre en colecciones en MongoDB.

8. Fin del programa.

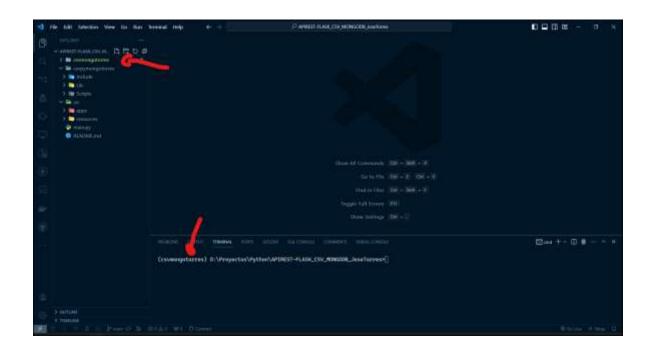
GitHub: https://github.com/JoseTorres022/APIREST-FLASK CSV MONGODB JoseTorres.git

# Python, CSV y MongoDB: Transformando Datos con Eficacia

Para tener una buena gestión de nuestros proyectos basados en Python, es el uso de entornos virtual, esto para aislar nuestros proyectos de otros que estén una misma carpeta, y por ende tener las versiones de paquetes para cada proyecto. Para instalar un entorno virtual, se es requerido estar en la carpeta del proyecto, para esto debemos instalar el entorno virtual:

- pip install virtualvenv (instala el módulo necesario)
- python -m vevn <<nombre\_del\_entorno>> (creamos un entorno virtual)
- .\<nombre\_del\_entorno>\Scripts\activate.bat (activamos nuestro entorno, sintaxis para Windows)

Después veremos una carpeta con el nombre de nuestro entorno, pero también en la terminal de VSCode vemos que antes de las rutas se muestra el nombre del entorno virtual previamente creado entre paréntesis, esto quiere decir que nuestro proyecto está aislado de los demás a su alrededor.



Por consecuente, nuestro proyecto está listo para ser construido. Como primera instancia debemos instalar un módulo/librería, que nos permita interactuar entre Python y MongoDB, esto lo hacemos mediante *PIP*:

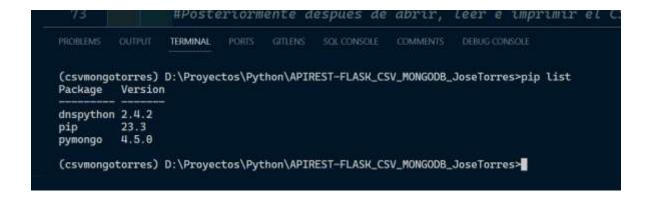
pip install pymongo

PyMongo es la mejor opción para usar MongoDB con Python. La biblioteca de controladores estándar es muy clara y fácil de usar. Podemos crear y modificar nuestras propias bases de datos y colecciones en unos pocos pasos.



Puede ser que ya tengamos *Pymongo* instalado, pero no esta de mas aplicar el anterior comando. Si no, hará el proceso de instalación del módulo. Para ver la lista de módulos instalados, usamos:

pip list



Este nos despliega la lista de módulos que tenemos en nuestro proyecto, pero también los podemos tener de manera global en nuestro sistema, aunque se recomienda instalar esto módulos directamente en nuestros proyectos ya que podemos trabajar sobre una versión especifica.

## Python Code: La introducción

#### Librerías necesarias

Para este proyecto solo usamos tres liberrias, una será para leer carpetas y su contenido, el otro será para trabajar con CSVs y por último el módulo para interactuar entre Python y MongoDB.



#### Os

"OS" en Python se refiere al módulo **os**, que es una parte estándar de la biblioteca estándar de Python. Este módulo proporciona una manera de utilizar funcionalidades dependientes del sistema operativo, como leer o escribir en el sistema de archivos, manipular rutas de archivos, trabajar con variables de entorno del sistema y realizar otras operaciones relacionadas con el sistema operativo.

#### **CSV**

El módulo **csv** en Python es parte de la biblioteca estándar y proporciona funcionalidades para trabajar con archivos CSV (Comma Separated Values). Los archivos CSV son una forma común de almacenar datos tabulares, donde cada fila de datos está representada como una línea en el archivo y los valores de cada columna están separados por comas u otro delimitador.

#### **Pymongo**

En Python pymongo es un controlador para MongoDB, que es un sistema de gestión de bases de datos NoSQL (orientado a documentos). MongoDB almacena datos en formato JSON (JavaScript Object Notation) y es muy adecuado para aplicaciones que manejan grandes volúmenes de datos no estructurados o semiestructurados.

## Python Code: Conexión, Clases y funciones

 Para hacer una conexión a la base de datos MongoDB, es muy sencilla solo hay que realizar el siguiente condigo.

```
#Conexion entre la app y mongodb
client=MongoClient('localhost',27017)

#Seleccionamos la base de datos, si no existe la creara.
db=client['practicacsv_db']
```

2. Así también creamos una clase y una función, esta clase se instancia y se manda a llamar.

```
#Creamos un clase y definimos una funcion You, yesterday

Eclass PracticaCSV: ...

#Construccion de la aplicacion

app_main = PracticaCSV() #Creamos una instancia a la clase

app_main.LecturaCSV() #Mandamos a llamar a la clase
```

3. Por último, cerramos la conexión hacia la base de datos. Cerrar las conexiones a la base de datos de manera adecuada es una práctica importante para garantizar la eficiencia, seguridad, consistencia y escalabilidad de las aplicaciones que interactúan con bases de datos.

```
91
92 #Cerramos la conexion con la base de datos
93 client.close You, yesterday • app funciona
```

## Python Code: Primeras líneas de construcción

Para hacer esto más interesante y a diferencias del proyecto inicial, en donde solo el código estaba diseñado a una sola estructura de un CSV, este programa es más dinámico ya que permite interactuar con los archivos sin importar su contenido. Creando las siguientes variables:

```
#Creamos un clase y definimos una funcion

class PracticaCSV:

def LecturaCSV(self):

#Ruta de la carpeta
ruta_carpeta = './src/resources/csv'

#Extencion del archivo
extencion_archivo = ""

#Lista para almacenar archivos con la extension
archivos_con_extencion = []

#Lectura de la carpeta con ListDir
archivos_carpeta = os.listdir(ruta_carpeta)
```

- Creamos una variable (ruta\_carpeta), este tendrá la ruta de la carpeta contenedora.
- Una variable el tipo de archivo (extencion\_archivo), esto para buscar específicamente un ".csv", pero se pude dejar vacío y se mostraran todos los archivos de la carpeta.
- 3. Una variable que tendrá una lista para almacenar (archivo\_con\_etencion) los archivos con la extensión deseada.
- 4. Por último, una variable donde se leerá (archivos\_carpeta) la carpeta contenedora.

#### Python Code: Iterando sobre la carpeta contenedora

Para iterar de forma adecuada, se necesita de un for, la mejor manera de recorrer una lista, que en este caso se tratan como objetos.

```
#For para iterar sobre todos los archivos en las carpetas

for archivo in archivos_carpeta:

#Comprobando si el archivo tiene la extension deseada

if archivo.endswith(extencion_archivo):

#agregamos el elemento al final de la lista

archivos_con_extencion.append(archivo)

#Se imprime la lista de archivos con extencion (CSV)

print(f*Archivos con la extension [{extencion_archivo}]:*)

#Se imprime los archivos que contiene la carpeta/ruta carpeta

print(*\nArchivos en carpeta:\n*, archivos_con_extencion)

print(*\nArchivos de archivos*)
```

- 1. Al **for** se le asigna una variable (*archivo*) que tomas el valor del próximo elemento en la secuencia durante cada iteración del bucle.
- 2. La variable (*archivos\_carpeta*) es la colección de elementos sobre la que se va a iterar.
- 3. Dentro del *for*, se estructura un *if* el cual tiene como condición (archivo), el cual es una expresión que se evalúa como **True** o **False**. En consecuencia, se usa el método **endswith**, el cual es un método de cade que se usa para determinar si una cadena termina con un sufijo especifico. Que es este caso (*extencion\_archivo*), debe ser ".csv".
- 4. Dentro del *if*, con la variable (archivo\_con\_extencion) le agregamos el método **append** para agregar el elemento al final de lista.
- 5. Todo lo anterior sucede dentro del *for*.
- 6. Imprimimos la lista de archivos con la extensión deseada.
- 7. Así también como la lista de los archivos de la carpeta.

# Python Code: índices a los archivos

Como se ha mencionado a lo largo de este trabajo, el programa tiene cosas interesantes, y una de ellas es el agregado de índices numéricos ascendentes a la impresión en pantalla de los CSVs.

```
#Se agrega indices a la lsita de archivos

for indice, archivo in enumerate(archivos_con_extencion, start=1):

print(f"[{indice}] {archivo}") #Se muestran los archivos indexados/enumenrados
```

## Python Code: Lecturas y vistas de CSVs

Después de que se enlisten los archivos CSVs y mostrar los con un índice respectivo, ahora podemos seleccionar que CSv queremos que se lea y nos lo muestre ya transformado en un diccionario.

```
Try:

| State | State
```

Esta parte del código va dentro de un *Try Exception*, es decir, si sucede algún error se mostrará cual fue el error o código del error real, esto sirve para identificar que es lo que está dando problemas

- Con una variable (*indice\_seleccionado*) el cual es una variable tipo **int**dentro un **input**, se le pregunta al usuario que ingrese un numero dentro
  del rango de la lista, esto es así, porque, es para poder ver un CSV
  almacenad en la carpeta contenedora.
- 2. Con este if es una forma compacta de escribir dos comparaciones simultáneamente. Esta expresión verifica si la variable (*índice\_seleccionado*) es mayor o igual a 1 y al mismo tiempo es menor o igual a la longitud de la lista (*archivos\_con\_extension*) haciéndolo con len, el cual calcula la longitud o el número de elementos de un objeto iterable.

- 3. Después se lee la carpeta y se le pasa la ruta de la carpeta y el archivo seleccionado. Imprimiendo la ruta del archivo seleccionado.
- 4. Con **with open**, damos comienzo a la lectura, pasando por la apertura del archivo CSV y la lectura de este en modo **r**(**read**).
- Con la variable contenido, leemos el CSV como si fuera un diccionario con el método DictReader con un formato propio de un diccionario en Pyhon.
- 6. Luego lo almacenamos en un lista llamada data=[]
- 7. Ahora con un **for**, iteramos las filas del archivo CSV seleccionado y lo convierte en diccionario.
- 8. Se imprime el contenido del CSV ya transformado en un diccionario.
- 9. Por último se agrega cada fila del diccionario en la lista data=[]
- 10. Se termina este bloque con else por si se ingresó un índice erróneo y sale del programa, con except, es para ver si surgió un error durante la ejecución.

# Python Code: Insertando datos CSVs en colecciones MongoDB

Para insertar los datos correspondientes de cada archivo CSV, se es necesario, preguntar al usuario si quiere guardar el CSV después de ser impreso o mostrado al usuario. Cuando se elija la opción de **SI**, estos datos del CSVs, serán insertados en colecciones en una base de datos en MongoDB.

```
#Posteriormenta despues de abrir, levr e imprimir el CSV, se la progunta al asuario

# si quiere quardarle en la base de datos

opcion=int(input(f*\ngGuardar [[archivo_seleccionado]] en la base de datos? \nl. Si \n2. No \nRespuesta: "])

if opcion=1:

print(f*\nEstamos trabajando con: '[archivo_seleccionado]'"]#Se le indice al susurio que con esta trabajando.

#Seleccionames | g coleccion en la que desenmes guardar los datos

#Esto se haca, usando el nombre del archivo sin | | #artencian como el nombre de | g coleccion

nombre_coleccion=archivo_seleccionado.split(',')[0]#Dividiacs el nombre y | | #stension, quadando solo el nombre

coleccion=db[nombre_coleccion]#Guarda | | coleccion con el nombre del #rchivo CSV

coleccion.insert_many(data)#Inserte los datos del diccionario en | | coleccion

#15e:

return f*El archivo '[archivo_seleccionado]' no se guardo."
```

- En la pregunta de insersion del CSV al usuario a la base de datos, se muestra el archivo con el cual se está trabajando con la variable archivo\_seleccionado.
- 2. Con un **if** se realiza la condición de que, si es **1(Si/si)** este entra al bloque de intrudcciones y se muestra con que archivo CSV se estra trabajando.
- 3. Luego viene lo más interesante, es, guardar el CSV en un colección,pero con el nombre prorpio de CSV.
- 4. En la cariable nombre\_coleccion, se le pasa la variable archivo\_seleccionado con el método Split(' . ')[0], es lo que hace es separa una cadena, que este caso es el nombre el "nombre\_archivo.csv", dividiendo el nombre y la extensión, por esos se le pasa el punto el al Split, dejando solo el nombre del archivo CSV.
- 5. Una vez dejando el nombre del archivo CSV, con la variable colección se le pasa la variable con el nombre de la colección db={nombre\_coleccion}, el cual es el nombre de la colección al nombre del archivo CSV correspondiente.

- 6. Por ultimo a la variable *colección* en conjunto con **insert\_many** y a este último se le pasa la lista **data={}**, para que inserte los datos del archivo CSV ya transformado en diccionarios en la colección correspondiente.
- 7. Se termina el bloque if con su respectivo else.
- 8. Termina el programa, una vez insertados los datos del CSV en una colección.

Por último, cerramos la conexión a la base de datos, esto se explicó al principio de este documento.

```
#Cerramos la conexion con la base de datos

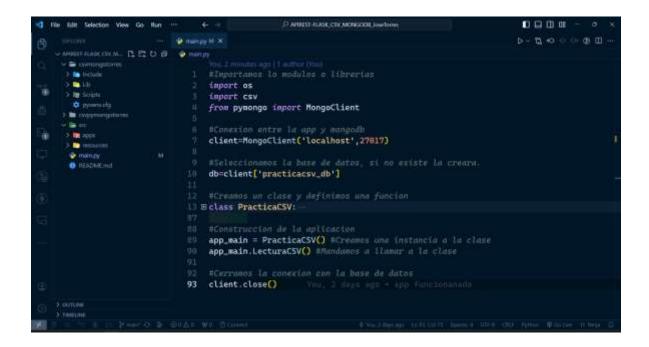
P3 client.close

P3 vou, 2 days ago • app funcion

P3 client.close
```

# Python Code: Código final

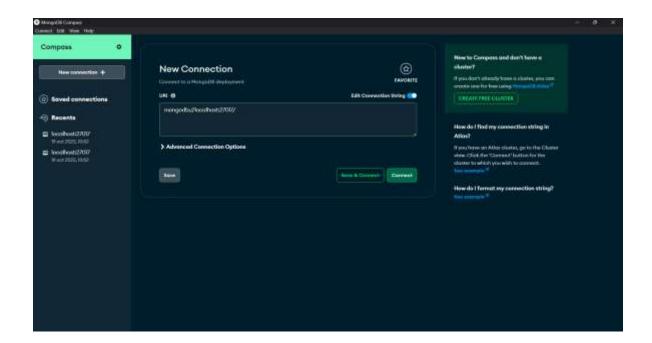
Este es el código final del programa en Python, este programa fue subido a GitHub para ser compartido y mejorado por quienes le vean o simplemente para aprender del mismo.



## MongoDB: Sin relaciones es mejor

Como se mencionó anteriormente, los archivos CSV se almacenaron en MongoDB en colecciones, los cuales son agrupaciones de documentos almacenado en la base de datos. Cada documento es una estructura de datos JSON (*JavaScritp Object Notation*) que puede contener varios campos con sus valores correspondientes. Asu vez, las colecciones son análogas a las tablas en los sistemas de bases de datos relacionales, pero a diferencia de las tablas, los documentos en una colección no necesitan seguir un esquema fijo.

Esto significa que los documentos en una misma colección pueden tener estructuras diferentes, lo que brinda flexibilidad en el diseño de la base de datos. Gracias a las colecciones y que estos datos están en documentos en formato JSON, fue posible almacenar los archivos CSV con su propia estructura, datos y filas.

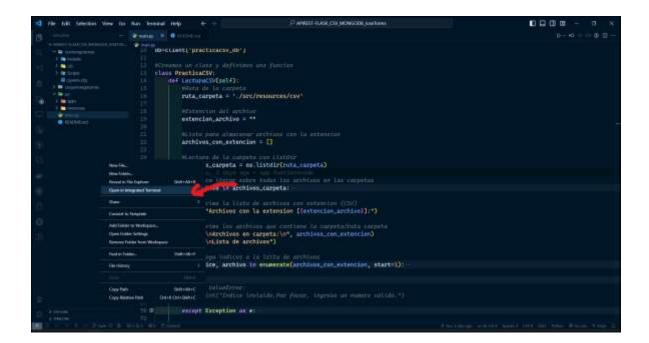


#### Python & MongoDB: Insertando datos CSVs

Ahora que se ha explicado el código, como funciona, es tiempo de ver los archivos CSV, en forma de documentos en MongoDB.

#### **Terminal VSCode**

El programa se ejecuta directamente en la terminal de VS Code. Primero en la carpeta del proyecto damos clic derecho y luego en **Open in Integrated Terminal** 



Lo primero que debemos de fijarnos es si nuestro entorno virtual se está ejecutando, si no, activarlo de la siguiente manera:

.\<nombre\_del\_entorno>\Scripts\activate.bat

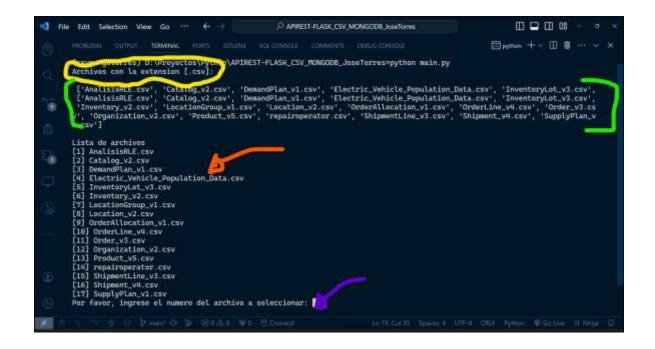


Después correr el script de Python, esto depende del nombre del archivo con la extensión **.py** 

Python <nombre\_script\_python>



Como se muestra en la siguiente pantalla, se muestran los archivos con la extensión deseada (amarillo), se nos muestran los archivos de la carpeta contenedora con la extensión deseada (verde), se muestran los archivos con respectivos índices para ser seleccionados (naranja), por último, se muestra la opción de seleccionar dentro del rango de la lista (morado).



Se selecciona un índice en el rango de la lista (morado), se muestra la ruta del archivo seleccionado (verde), luego se muestra el contenido del archivo CSV, dependiendo del contenido, es lo que se va a demorar en terminar de leer, mostrarlo y terminar (rosa).

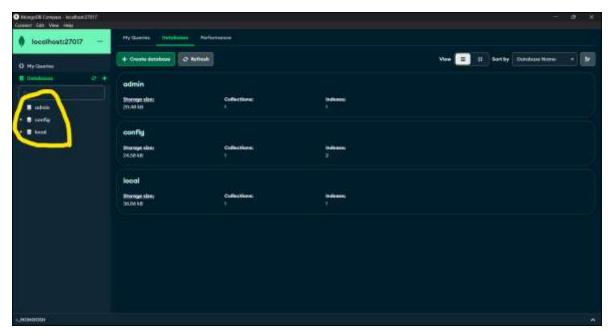
Después de imprimir el contenido del CSV, se cuestiona si realmente dicho CSV quiere ser almacenado en la base de datos, nótese que tiene el nombre del archivo con el que se esta trabajando (blanco), se muestran las respuestas **Si | No**, guardándolo en una colección con el nombre del archivo que se está trabajando (beige)

```
7-15160:89:00', 'quantity': '44', 'quantityUnits': 'EA', 'value': '132', 'valueCurrency': 'USD'}
{'shipment.shipmentIdentifier': 'ANQWZY', 'shipmentLineNumber': '188', 'shipment.shipmentType': 'INBOU
ND', 'order.orderIdentifier': '1800567500', 'orderLine.orderLineNumber': '108', 'dateCreated': '2821-8
7-08160:80:00', 'quantity': '56', 'quantityUnits': 'EA', 'value': '66080', 'valueCurrency': 'USD'}

¿Guardar [ShipmentLine_v3.csv] en la base de datos'
1. Si
2. No
Respuesta:
```

## MongoDB: Base de datos y colecciones

Estamos en la interfaz de MongoDB, en el cual se nos muestran las bases de datos (amarillo), pero cuando se almacenen los archivos CSVs, se mostrara una base de datos donde contendrá las colecciones de los archivos CSVs con sus respectivos nombres.



#### Python & MongoDB: Procesando diccionarios a colecciones

Cuando la opción se **Si (1)**, este pondrá en ejecución el script para almacenar los diccionarios (azul). Se muestra con que archivo se esta trabajando, y con eso termina el programa.

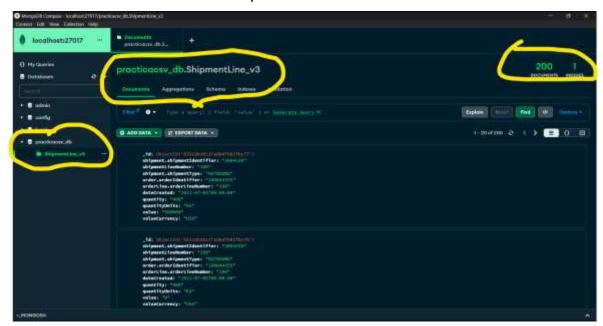
```
ND', 'order.orderIdentifier': '1980567500', 'orderLine.orderLineNumber': '198', 'dateCreated': '2021-0 7-08T00:00', 'quantity': '56', 'quantityUnits': 'EA', 'value': '66080', 'valueCurrency': 'USD'}

¿Guardar [ShipmentLine_v3.csv] en la base de datos?
1. Si
2. No
Respuesta: 1

Estamos trabajando con: 'ShipmentLine_v3.csv'

(csymongotorres) D:\Proyectos\Python\APIREST-FLASK_CSV_MONGODB_JoseTorres>
```

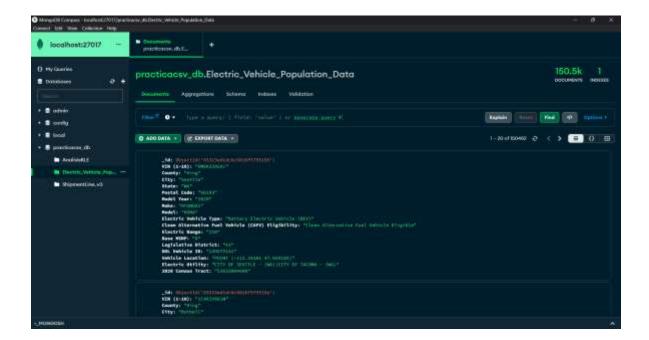
Si nos regresamos a MongoDB, y hacemos *refresh*, se nos muestra la base de datos, el nombre de la colección corresponde al nombre del CSV, y por ende se nos muestran el total de documentos que tiene dicha colección.



Así podemos hacerle con cada archivo CSV, que este en la carpeta contenedora, no importa cuantos CSVs sean, no importa su estructura y la cantidad de datos y/filas que estos contengan, este programa tiene la capacidad de procesarlos, transformarlos en diccionarios y almacenarlos en la base de datos.

#### Ejemplo dataset 150k

Aquí un ejemplo de un dataset de más de 150k filas y esto fueron procesados correctamente. Se puede llegar a demorar un par de minutos, pero se pude mejorar el programa a futuro, para que sea más eficiente.



#### **Conclusiones**

En conclusión, la combinación de Python, archivos CSV y MongoDB ofrece un poderoso conjunto de herramientas para gestionar datos de manera eficiente y efectiva en el mundo digital actual. Python, con su sintaxis clara y su amplio ecosistema de bibliotecas, permite a los desarrolladores procesar datos de archivos CSV de manera intuitiva. La capacidad de leer y escribir archivos CSV de forma nativa en Python facilita la manipulación de datos tabulares, mientras que las bibliotecas especializadas proporcionan opciones avanzadas para tareas complejas.